

Méthodologie du projet — Modèle IRB-A / IFRS 9 (Crédit Retail & PME)

Auteur : Rodrigue KOFFI

Périmètre : Portefeuille de crédit à la consommation (German Credit Data), enrichi et retraité pour simuler un portefeuille bancaire réaliste (Retail / PME / Corporate-SME).

0. Pourquoi ce document existe

Ce mémo documente les points méthodologiques centraux du pipeline, en particulier :

1. **La PD utilise un Long Run Average (LRA)**, désormais calibré au niveau de la cellule ($\text{populationSegment} \times \text{riskGradeClass}$) et stabilisé par une pondération de crédibilité actuarielle avant tout contrôle de monotonie (section 5).
2. **La segmentation du risque se construit en deux temps distincts** : une segmentation de POPULATION non supervisée par capacité économique (DBSCAN + KMeans, section 3), puis une segmentation de RISQUE supervisée par le défaut à l'intérieur de chaque population (algorithme de Belson, section 4), validée par une analyse de variance (ANOVA).
3. **La Marge de Conservatisme (MoC)** est construite selon les catégories A / B / C, appliquées elles aussi au niveau de la cellule (section 6).

Il documente, module par module, les formules utilisées, leur justification économique, et les articles réglementaires correspondants (CRR — Règlement UE 575/2013 tel que modifié par CRR2/CRR3, CRD IV/V, EBA Guidelines, IFRS 9), ainsi que les techniques statistiques/actuarielles classiques mobilisées (algorithme de Belson, théorie de la crédibilité de Bühlmann) qui ne sont pas d'origine réglementaire mais relèvent de bonnes pratiques de modélisation statistique.

Avertissement de portée : le jeu de données source (German Credit Data, 1000 dossiers, 10 variables) ne contient ni date, ni segment PME, ni flux de recouvrement, ni revenu. Toutes les données temporelles, le périmètre PME/Corporate, les revenus, les flux de recouvrement et les coûts de gestion du contentieux sont **simulés** pour permettre un pipeline méthodologiquement complet. Chaque donnée simulée est signalée dans le code (`src/*.py`) et ci-dessous.

Glossaire des termes clés

Cette section précède les sections méthodologiques et fixe une définition unique de chaque terme, pour éviter toute ambiguïté entre les modules (en particulier la notion de **défaut**, qui doit être lue de la même façon partout dans ce document et dans le code).

Obligor — Personne physique ou morale ayant une obligation de remboursement envers la banque (l'emprunteur). Le défaut est défini au niveau de l'obligor (Art. 178 CRR), pas du contrat : un obligor a un statut de défaut unique, même s'il détient plusieurs facilités.

Défaut (Default) — Au sens réglementaire (Art. 178 CRR), un obligor est en défaut si (a) la banque juge improbable qu'il rembourse intégralement ses obligations sans réalisation de la garantie (*Unlikelihood to Pay*), et/ou (b) il est en arriéré de plus de 90 jours consécutifs sur une obligation de crédit significative (*backstop* jours de retard).

Application dans ce projet : la base source ne fournit qu'un label binaire atemporel (`good / bad`), sans date ni motif. `defaultEverFlag` sert de vérité terrain simplifiée ("cet obligor connaîtra un défaut à un moment de sa vie"). `Tcg.py` lui assigne une **date de défaut unique** (`defaultDate`) dans la durée de vie du crédit. Le défaut est un événement **absorbant** : une fois survenu, l'obligor reste en défaut (pas de retour "in bonis" modélisé). C'est cette date unique qui est ensuite testée contre **plusieurs fenêtres d'observation annuelles successives** (le panel décrit en section 2.A) — et non contre une seule fenêtre à l'octroi — pour déterminer, à chaque point de vie du crédit, si le défaut survient dans les 12 mois qui suivent.

Population (populationSegment) — Groupe homogène de capacité économique (revenu, qualification, ratios d'endettement) auquel un obligor est affecté par clustering non supervisé (section 3), **avant** toute notation de risque. `populationModeste`, `populationIntermediaire`, `populationAisee`, ou `populationOutlierReview` pour les profils atypiques isolés.

Fenêtre de performance à 12 mois — Intervalle `(t, t+12 mois]` à partir d'un point d'observation `t` (pas nécessairement l'octroi), utilisé pour mesurer si un défaut survient dans l'horizon réglementaire d'un an (Art. 178 CRR, EBA GL/2016/07).

Anniversaire vs cycle calendaire — approche retenue (à ne pas confondre) : le projet combine délibérément les deux logiques, à deux étapes différentes :

- *Génération des points d'observation* : ancrée sur la **date anniversaire du contrat** (`originationDate` , puis +12 mois, +24 mois, ...), propre à chaque dossier — pas sur un calendrier civil fixe (1er janvier).
- *Agrégation de la série pour la LRA* : chaque observation est étiquetée par l'**année calendaire** dans laquelle tombe son anniversaire (`performanceYear = t.year`), et non par l'âge du crédit. C'est ce qui permet de faire ressortir correctement les années de choc macroéconomique (2012, 2020) dans le calcul de la LRA (section 5), quel que soit l'âge des crédits qui y contribuent cette année-là.

PD (Probability of Default) — Probabilité qu'un obligor fasse défaut dans les 12 mois. On distingue la **PD TTC** (Through-The-Cycle, LRA + MoC, utilisée pour le capital IRB) de la **PD PIT** (Point-In-Time, ajustée des conditions actuelles, utilisée pour l'IFRS 9).

LRA (Long Run Average) — Moyenne des taux de défaut annuels observés sur un historique représentatif d'un cycle économique complet (section 5), construite à partir du panel d'observations et non d'un flag unique par dossier, calibrée au niveau de la cellule (`populationSegment × riskGradeClass`), et stabilisée par une pondération de crédibilité actuarielle avant tout contrôle de monotonie.

Crédibilité actuarielle (credibility, Bühlmann) — Technique statistique classique (assurance/actuariat) consistant à pondérer une estimation propre à un segment fin par un facteur croissant avec la taille de son échantillon, le complément étant apporté par une estimation plus large et donc plus stable (le "prior"). Utilisée ici pour stabiliser la LRA de cellules (`population × grade`) à faible effectif (section 5).

MoC (Margin of Conservatism) — Marge additive appliquée à la PD LRA de chaque cellule pour couvrir l'incertitude résiduelle, décomposée en catégories A (erreur d'estimation générale), B (déficiences de données/méthode identifiées) et C (changements de contexte non encore reflétés) — détail en section 6.

Algorithme de Belson — Méthode de segmentation binaire réursive supervisée (D.J. Belson, 1959), précurseur des méthodes AID/CHAID : à chaque nœud, elle sélectionne la variable et le seuil qui maximisent l'association statistique (test du χ^2) avec une variable cible binaire. Utilisée ici (section 4) pour construire les classes de risque à l'intérieur de chaque population, en utilisant `defaultEverFlag` comme cible.

LGD (Loss Given Default) — Proportion de l'exposition effectivement perdue en cas de défaut, après recouvrement et déduction des coûts (section 7).

EAD (Exposure At Default) — Montant de l'exposition au moment du défaut (section 8).

Grade / Pool de risque (riskGradeClass) — Classe homogène de risque (`veryLow` à `veryHigh`) à laquelle un obligor est affecté par l'algorithme de Belson, **à l'intérieur de sa population** (section 4). Le même libellé de grade peut porter des PD différentes selon la population (section 5).

SICR (Significant Increase in Credit Risk) — Dégradation significative du risque de crédit depuis l'octroi, déclenchant le passage en Stage 2 sous IFRS 9 (section 9).

Stage IFRS 9 — Classification en 3 niveaux (Stage 1 : sain, Stage 2 : SICR avéré, Stage 3 : en défaut) déterminant l'horizon de calcul de l'ECL.

ECL (Expected Credit Loss) — Perte de crédit attendue, calculée comme $PD \times LGD \times EAD$, actualisée, sur un horizon de 12 mois (Stage 1) ou à maturité (Stage 2/3).

RWA (Risk Weighted Assets) — Actifs pondérés du risque, base de calcul du capital réglementaire IRB (section 10).

Périmètre (Retail / Retail-SME / Corporate-SME) — Segmentation réglementaire du portefeuille définissant le champ d'application du modèle (section 1). À ne pas confondre avec `populationSegment` (section 3), qui est une segmentation par capacité économique, orthogonale au périmètre réglementaire.

Train / Out-Of-Time (OOT) — Découpage chronologique du panel d'observations en deux sous-périodes pour tester la stabilité dans le temps du pouvoir discriminant : Train = années antérieures à un seuil fixé (ici 2022), OOT = années postérieures ou égales à ce seuil (section 12).

AUC (Area Under the ROC Curve) — Mesure du pouvoir discriminant d'un score ou d'un classement face à un événement binaire (défaut) : 0,50 = aucun pouvoir discriminant, 1,00 = discrimination parfaite (section 12).

Gini — Transformation linéaire de l'AUC ($Gini = 2 \times AUC - 1$), échelle usuelle en risque de crédit (section 12).

VIF (Variance Inflation Factor) — Mesure de la colinéarité d'une variable explicative avec les autres variables d'un même modèle ($VIF = 1 / (1 - R^2)$ de sa régression contre les autres) ; un $VIF > 5$ signale une redondance à traiter (section 12).

ANOVA (analyse de variance à un facteur) — Test statistique comparant la variance "between" (entre groupes) à la variance "within" (au sein des groupes) via la statistique F, utilisé ici pour vérifier l'homogénéité intra-classe / hétérogénéité inter-classe exigée par l'Art. 170 CRR (section 4).

1. Périmètre (`perimeterDefinition.py`) — CRR Art. 142, 147, 123

Chaque obligor est classé :

- `RETAIL_CONSUMER` : particulier, crédit à la consommation classique.
- `RETAIL_SME` : petite activité indépendante, exposition < seuil Art. 123 CRR (1 M EUR) → reste en portefeuille Retail.

- `CORPORATE_SME` : sous-population simulée pour illustrer l'ajustement de corrélation "taille de firme" (Art. 153(4)).

Limite assumée : les montants du dataset restant tous < 1 M EUR, une PME y resterait en toute rigueur dans le portefeuille Retail (Art. 123). Le segment `CORPORATE_SME` est un choix pédagogique explicite.

Revenu mensuel et données PME (chiffre d'affaires, effectifs) sont simulés car absents de la base source mais indispensables au calcul des ratios d'endettement, à l'ajustement de corrélation PME, et — nouveauté de cette version — à la segmentation de population de la section 3.

Résultat sur le portefeuille simulé : `RETAIL_CONSUMER` 949 obligors (94,9 %), `RETAIL_SME` 34 (3,4 %), `CORPORATE_SME` 17 (1,7 %).

2. Chronologie et panel d'observations (`TCG.py`) — CRR Art. 178

Deux notions de temps distinctes :

A. Panel d'observations annuelles (calibration LRA)

La bonne pratique EBA GL/2017/16 observe chaque dossier à **plusieurs reprises au cours de sa vie** (anniversaires successifs), et teste à chaque point s'il fait défaut dans les 12 mois qui suivent CE point précis :

```
pour chaque dossier, tant qu'il est vivant et que la fenêtre est entièrement réalisée :
    t = originationDate, originationDate+12m, originationDate+24m, ...
    default12mFlag(t) = 1 si t < defaultDate <= t + 12 mois -> le dossier sort de la
population, arrêt
    default12mFlag(t) = 0 si aucun défaut dans (t, t+12 mois] ET le crédit est encore
actif à t+12 mois
    (observation exclue si la fenêtre n'est pas encore entièrement réalisée à la date
d'arrêt,
    ou si le crédit arrive à échéance avant la fin des 12 mois -> fenêtre censurée)
```

Exemple concret : origination en 2011, défaut en 2014. Observation 2011 (fenêtre 2011→2012) : `default12mFlag` = 0. Observation 2012 (fenêtre 2012→2013) : `default12mFlag` = 0. Observation 2013 (fenêtre 2013→2014) : défaut constaté → `default12mFlag` = 1, le dossier sort de la population. Ce dossier contribue ainsi correctement à la série de taux de défaut annuels, à la bonne année (2013), plutôt que de disparaître silencieusement.

Implémenté dans `buildAnnualPerformancePanel()`, qui produit un **panel** (plusieurs lignes par dossier). Sur le portefeuille simulé : 1 143 observations annuelles sur 774 dossiers actifs au moins une fois dans l'historique (2010–2023).

Un indicateur diagnostique `firstYearDefaultFlag` (défaut dans la 1ère année uniquement) est conservé à titre de comparaison dans les exports, mais **n'alimente plus la calibration LRA**.

B. Statut du livre à la date d'arrêté (staging IFRS 9)

À la date de reporting (`OBSERVATION_DATE` = 2024-06-30), chaque dossier est classé `ACTIVE`, `DEFAULTED` ou `MATURED`. Seuls `ACTIVE` et `DEFAULTED` entrent dans le calcul de l'ECL. Un proxy d'arriérés (`daysPastDue`) est simulé pour le backstop des 30 jours de l'IFRS 9.

3. Segmentation de la POPULATION (`populationSegmentation.py`) — CRR Art. 170, NOUVEAU MODULE

Justification

L'Art. 170 CRR exige une différenciation du risque fondée sur des caractéristiques **homogènes intra-classe**. Ce principe est appliqué ici en amont même de la notation de risque : deux obligors dont la capacité économique (revenu, qualification, endettement relatif) diffère fortement n'appartiennent pas à la même population statistique, et ne doivent donc pas être calibrés par le même modèle de PD — quand bien même ils recevraient, par ailleurs, le même grade de risque. Concrètement : un obligor à 1 000 EUR/mois et un obligor à 5 000 EUR/mois classés tous deux "veryLow" par leurs caractéristiques de risque propre (épargne, ancienneté, montant emprunté...) ne portent pas nécessairement la même PD réelle — leur robustesse face à un choc de revenu, leur reste-à-vivre, et donc leur probabilité de défaut future, diffèrent structurellement.

Méthode

Variables utilisées (`POPULATION_SEGMENTATION_FEATURES`) : `monthlyIncomeEur`, `jobSkillLevel`, `creditToAnnualIncomeRatio`, `installmentToIncomeRatio` — exclusivement des variables de capacité économique, connues à l'octroi, distinctes des variables de risque pur utilisées à l'étape 4 (épargne, garantie logement...).

1. **Standardisation** (`StandardScaler`, moyenne 0, écart-type 1) des 4 variables.
2. **DBSCAN** (`eps=config.POPULATION_DBSCAN_EPS=1.5`, `min_samples=config.POPULATION_DBSCAN_MIN_SAMPLES=15`) détecte les profils atypiques (label `-1`), isolés en `populationOutlierReview` et exclus du KMeans.
3. **KMeans** (`k=config.N_POPULATION_SEGMENTS=3`, `n_init=20`, `random_state=42`) sur la population cœur.
4. Les clusters bruts sont classés par **revenu mensuel moyen croissant** et mappés vers `config.POPULATION_SEGMENT_LABELS_ORDERED = ["populationModeste", "populationIntermediaire", "populationAisee"]`.

Choix de k=3

`N_POPULATION_SEGMENTS` est un paramètre de `config.py`. La valeur 3 a été retenue après comparaison du score de silhouette pour $k \in \{2, 3, 4, 5\}$ sur la population cœur : $k=3$ offre un score de silhouette de 0,456 (bonne séparation) avec des effectifs raisonnablement équilibrés (631 / 209 / 145), contre un score plus faible et des groupes plus fragmentés au-delà. Un k plus élevé (5, par exemple) fragmenterait excessivement les cellules croisées avec les 5 grades de risque de la section 4 sur un portefeuille de seulement ~1000 obligors — arbitrage documenté ici plutôt que caché.

Résultat sur le portefeuille simulé

Population	Effectif	Revenu mensuel moyen	Qualification moyenne	Ratio d'endettement moyen
populationModeste	209	1 498 EUR	0,93	0,121
populationIntermediaire	631	2 285 EUR	2,01	0,116
populationAisee	145	3 644 EUR	2,98	0,125
populationOutlierReview	15 (1,5 %)	1 455 EUR	0,73	0,546

Silhouette score ($k=3$, population cœur) = **0,456**. Les profils atypiques se distinguent nettement par un ratio d'endettement moyen presque 5 fois supérieur aux populations cœur — cohérent avec l'objectif de la détection DBSCAN (profils économiquement incohérents).

Résultat de transparence : une ANOVA (section 4) montre que `populationSegment` seul n'explique pas significativement `defaultEverFlag` sur ce portefeuille ($F=0,60$, $p=0,55$, $\eta^2=0,001$). Ce n'est PAS l'objectif de cette étape — `populationSegmentation.py` ne construit rien à partir du défaut — mais cela doit être lu honnêtement : la segmentation de population sert la validité statistique de la calibration (section 5), pas à elle seule la discrimination du risque.

4. Classes de risque par ALGORITHME DE BELSON (`riskClustering.py`) — CRR Art. 170

Pourquoi remplacer le clustering non supervisé par une méthode supervisée

La version précédente utilisait DBSCAN + KMeans (non supervisé, sur les variables de risque) pour construire les classes, puis les ordonnait a posteriori par taux de défaut observé. Cette méthode ne produisait qu'un pouvoir discriminant faible ($Gini \approx 0,04$, cf. ancienne section 11). L'algorithme de Belson (D.J. Belson, *"Matching and Prediction on the Principle of Biological Classification"*, 1959), précurseur des méthodes AID/CHAID, construit au contraire les classes en utilisant directement le défaut observé comme critère de coupure — ce qui améliore mécaniquement la séparation des classes, au prix d'un risque de sur-apprentissage à surveiller (section 12).

Algorithme

Exécuté **séparément pour chaque** `populationSegment` (hors `populationOutlierReview`, dont les obligors reçoivent directement `riskGradeClass = "outlierReview"`).

Étape 1 — Sélection de la meilleure coupure à chaque nœud. Pour un nœud (sous-ensemble d'obligors) et pour chaque variable candidate (`CLUSTERING_FEATURES` : `age`, `jobSkillLevel`, `savingAccountScore`, `checkingAccountScore`, `housingCollateralProxyScore`, `creditAmountScaledLog`, `durationMonths`, `installmentToIncomeRatio`, `creditToAnnualIncomeRatio`), on teste un ensemble de seuils candidats `s` (valeurs distinctes si la variable a peu de modalités, sinon jusqu'à `config.BELSON_MAX_CANDIDATE_THRESHOLDS=8` quantiles). Pour chaque coupure (variable, seuil), on construit la table de contingence 2×2 :

	défaut = 0	défaut = 1
gauche (<= s)	a	b
droite (> s)	c	d

et on calcule la statistique du Chi² d'indépendance (avec correction de continuité de Yates) :

```
chi2 = sum( (observe_ij - attendu_ij)^2 / attendu_ij ) pour i,j dans la table 2x2
attendu_ij = (somme_ligne_i * somme_colonne_j) / n_total
```

La coupure retenue est celle qui **maximise le Chi²** parmi toutes les variables et tous les seuils testés (sous contrainte `taille_gauche >= BELSON_MIN_LEAF_SIZE` et `taille_droite >= BELSON_MIN_LEAF_SIZE`, avec `BELSON_MIN_LEAF_SIZE=25`).

Étape 2 — Critère d'arrêt. Le nœud est scindé si et seulement si :

```
p_value(meilleure coupure) < config.BELSON_CHI2_PVALUE_THRESHOLD (=0.05)
ET profondeur < config.BELSON_MAX_DEPTH (=3)
ET taille du nœud >= 2 * BELSON_MIN_LEAF_SIZE
ET le nœud contient au moins un défaut et un non-défaut
```

Sinon, le nœud devient une feuille terminale. La profondeur maximale de 3 borne le nombre de feuilles à 2³=8 par population.

Étape 3 — Fusion des feuilles en grades. Les feuilles sont triées par taux de défaut observé croissant :

```
tauxDéfaut(feuille) = totalDéfauts(feuille) / effectif(feuille)
```

puis fusionnées itérativement : à chaque itération, on fusionne la paire de feuilles **adjacentes** (dans l'ordre trié) dont l'écart de taux de défaut est le plus faible, jusqu'à obtenir au plus `config.N_RISK_GRADES=5` groupes. La monotonie du taux de défaut par groupe final est garantie par construction (fusion d'éléments déjà triés). Si l'arbre produit moins de feuilles que 5, les étiquettes de grade sont échantillonnées parmi `["veryLow", "low", "medium", "high", "veryHigh"]` en conservant les deux extrêmes (`numpy.linspace` arrondi), pour ne pas artificiellement resserrer l'échelle de risque.

Cas de repli : si une population a moins de `2×BELSON_MIN_LEAF_SIZE` obligors ou ne contient qu'une seule valeur de `defaultEverFlag`, un grade unique (`medium`) lui est attribué, documenté comme limite.

Résultat sur le portefeuille simulé

Population	Feuilles Belson	Grades finaux
populationModeste (209)	4	4 (veryLow 10,0 % — low 13,9 % — high 36,2 % — veryHigh 62,2 %, taux de défaut observés bruts)
populationIntermediaire (631)	7	5 (veryLow 6,3 % — low 21,4 % — medium 27,7 % — high 49,7 % — veryHigh 83,3 %)
populationAisee (145)	3	3 (veryLow 11,9 % — medium 32,0 % — veryHigh 52,8 %)
populationOutlierReview (15)	—	outlierReview (26,7 %)

Validation ANOVA (Art. 170 CRR)

Pour chaque `populationSegment`, une ANOVA à un facteur (`scipy.stats.f_oneway`) est menée sur `defaultEverFlag` groupé par `riskGradeClass` :

```
F = (SS_between / (k-1)) / (SS_within / (N-k))
SS_between = sum_i( n_i * (moyenne_i - moyenne_globale)^2 )      pour chaque groupe i
SS_within  = sum_i( sum_{x dans groupe i} ( x - moyenne_i )^2 ) )
eta2 = SS_between / (SS_between + SS_within)
```

Résultats sur le portefeuille simulé :

Périmètre	F	p-value	η^2
riskGradeClass au sein de populationModeste	14,69	< 0,0001	0,177
riskGradeClass au sein de populationIntermediaire	44,37	< 0,0001	0,221
riskGradeClass au sein de populationAisee	9,84	0,0001	0,122
populationSegment (diagnostic)	0,60	0,550	0,001

Les trois premières lignes confirment une hétérogénéité inter-classe hautement significative ($p < 0,001$) à l'intérieur de chaque population, avec une taille d'effet modérée à substantielle (η^2 entre 0,12 et 0,22 — au sens des conventions usuelles de Cohen, un $\eta^2 > 0,14$ est considéré comme un effet "large"). La dernière ligne confirme, à titre diagnostique, que `populationSegment` seul n'est pas un facteur de risque significatif (cf. section 3) — cohérent avec le fait qu'il n'a pas été construit à cette fin.

Limite assumée : parce que l'algorithme de Belson utilise `defaultEverFlag` pour choisir ses propres coupures, cette ANOVA est en partie mesurée **en échantillon** (in-sample) — une significativité élevée est structurellement plus facile à obtenir qu'avec une méthode non supervisée. La section 12 (Train/OOT) apporte un contrôle indépendant de cette limite.

5. PD Long Run Average — EBA GL/2017/16 (§88-94), CRR Art. 180

Formule de base

```
PD_LRA_brute(population, grade) = moyenne_années( tauxDéfautAnnuel(population, grade,
année) ) pour année ∈ [2010, 2023]
```

où `tauxDéfautAnnuel` provient du **panel d'observations annuelles** (section 2.A), désormais croisé par la **paire** (`populationSegment`, `riskGradeClass`) et non plus par le seul grade — traduction directe, au niveau du calcul, du principe de la section 3.

Crédibilité actuarielle (nouveau de cette version)

La stratification à trois facteurs (`population × grade × année`) fragmente le panel : certaines cellules ne comptent que quelques observations annuelles (ex. `populationModeste × veryLow` : 6 observations sur l'historique complet).

Sur un échantillon aussi réduit, un taux de défaut brut de 0 % ou 100 % reflète le plus souvent le hasard d'échantillonnage plutôt qu'une vraie signature de risque, et contaminerait ensuite le contrôle de monotonie (une seule cellule extrême forcerait, par construction du Pool Adjacent Violators, la fusion de plusieurs grades voisins).

La correction retenue est la **crédibilité de Bühlmann**, technique actuarielle standard :

```
Z(cellule) = n(cellule) / ( n(cellule) + K )           K =
config.LRA_CREDIBILITY_K = 30

PD_LRA_credibilisée(population, grade) =
    Z(cellule) * PD_LRA_brute(population, grade)
    + (1 - Z(cellule)) * priorPopulation(population)

priorPopulation(population) = totalDéfaits(population) / totalObservations(population)
                               (agrégé sur TOUTES les cellules de grade de cette
population)
```

Plus une cellule est documentée (n grand), plus Z se rapproche de 1 et plus son propre taux pèse ; plus elle est fine, plus Z se rapproche de 0 et plus elle est ramenée vers le taux moyen de sa population. Avec $K=30$: une cellule à 6 observations (`populationModeste × veryLow`) a $Z \approx 0,167$, et son taux brut de 100 % est ramené à environ 43 % (moyenne pondérée avec le prior de population, 31,6 %) ; une cellule à 216 observations (`populationIntermediaire × high`) a $Z \approx 0,878$, quasiment inchangée par la crédibilisation (36